BiMotion: B-spline Motion for Text-guided Dynamic 3D Character Generation

原論文: https://arxiv.org/abs/2602.18873

ローカルPDF: `/Users/daisuketsukada/2602.18873.pdf`

概要

この論文は、テキスト指示に従って既存の3Dメッシュを動かす問題に対し、離散フレーム列ではなく連続な B-spline 曲線で動きを表現する `BiMotion` を提案しています。既存の feed-forward 手法は、固定長入力の制約のために長い動作を切り詰めたり間引いたりする必要があり、結果として「一部の動きしか出ない」「ぎこちない」という問題がありました。BiMotion は各頂点の軌跡を少数の制御点に圧縮し、固定容量の生成モデルでも長さの異なる動作を扱えるようにします。

何が新しいか

- 動作表現を、フレーム列ではなく連続・微分可能な B-spline 曲線に置き換えています。
- 可変長のモーションを、固定個数の制御点へ閉形式で圧縮する Laplacian 正則化付き B-spline ソルバを導入しています。
- VAE 側で B-spline 制御点に合わせた専用設計を入れています。
- 法線を使う `Normal Fusion`、制御点向けの `multi-level control-point embedding`、再投影後の `correspondence loss`、局所形状維持の `local rigidity loss` を組み合わせています。
- 学習用に、約 3.9 万本の可変長メッシュモーションと高品質なテキスト注釈からなる `BIMO` データセットを構築しています。

手法の要点

1. 各頂点の時間方向の変位系列を B-spline で近似し、固定数の制御点に変換します。
2. その制御点を B-spline 専用 VAE で潜在表現へ圧縮します。
3. 生成時は、初期メッシュとテキストを条件に diffusion/flow ベースの生成器でモーション潜在を生成します。
4. VAE デコーダで制御点を復元し、B-spline を任意長に再サンプリングして最終的なメッシュ列を得ます。

この設計の利点は、モーションの意味を「16フレームの断片」に押し込めず、連続軌跡として保持できる点です。論文中でも、B-spline は連続性、局所制御性、時間再パラメータ化の3点でモーション表現に向くと説明されています。

実験結果

論文では `AnimateAnyMesh`、`GVFDiffusion`、`V2M4` と比較しています。主張はかなり明確で、BiMotion は品質、テキスト整合、速度のバランスで最も強いです。

- VBench では `OC 0.187`、`TF 0.995`、`AQ 0.529`、`DD 0.800` で最高値でした。
- `SC` だけは `AnimateAnyMesh 0.951` がわずかに上で、BiMotion は `0.948` です。
- ユーザ評価では、`Text-to-Motion Agreement 4.095`、`Motion Plausibility 4.062`、`Motion Expressiveness 4.048` で全項目トップでした。
- 推論効率も高く、A100 上で `4.383 秒`、ピークGPUメモリ `1.246 GB` です。`AnimateAnyMesh` は `16.847 秒 / 3.102 GB`、`V2M4` は `1.672 時間 / 48.416 GB` と報告されています。

要するに、BiMotion は「より長く意味の通った動作を、より軽く生成できる」ことを示しています。

アブレーションから読めること

- B-spline 表現そのものが効いており、単純な線形補間より再構成誤差が大きく改善しています。
- Laplacian 正則化は、短い系列から制御点を求める際の不自然な揺れを抑えます。
- Normal Fusion は、空間的には近いがメッシュ上では別部位である点を見分けるのに効きます。
- 提案した control-point embedding は、従来の周波数埋め込みより細かな動きの再現に強いです。
- Local rigidity loss は、動かしながらも局所形状を保つのに寄与しています。

限界

- 非常に複雑で高周波な動きは、制御点数が少ないと表現しきれない可能性があります。
- 固定メッシュ前提なので、トポロジーが変わる動きには対応しません。
- 論文の貢献は「モーション表現の改善」が中心で、万能な4D生成そのものを解いたわけではありません。

図の抜粋

Figure 1: 提案の直感

BiMotion は、離散フレームを直接扱う既存法より、連続的で意味の通った軌跡を出せるという主張です。

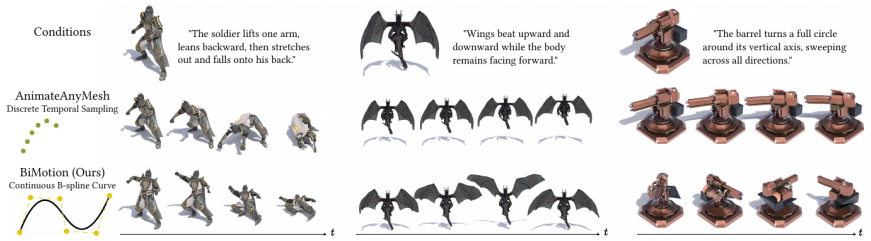

Figure 1. We propose **BiMotion**, a fast, feed-forward B-spline–based method for dynamic 3D character generation. It produces continuous, high-quality expressive motion trajectories aligned with rich textual prompts, outperforming discrete temporal sampling-based methods

Figure 1

Figure 2: 全体パイプライン

学習時は頂点差分を B-spline 制御点へ圧縮し、生成時はテキストと初期形状から制御点を復元して、そこからメッシュ列へ再投影します。

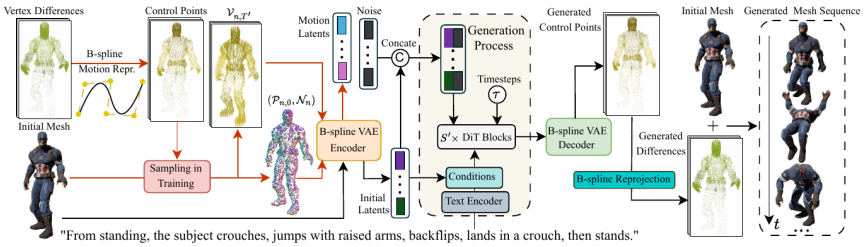

Figure 2. **Overview.** BiMotion uses a B-spline representation for motion generation. During training (red arrow), vertex differences are converted into control points and encoded into motion latents. During inference (black arrow), the initial mesh and the text prompt generate

Figure 2

Figure 3: B-spline VAE

提案VAEは、初期形状特徴と制御点特徴を組み合わせて潜在へ圧縮し、再度制御点へ戻す構成です。

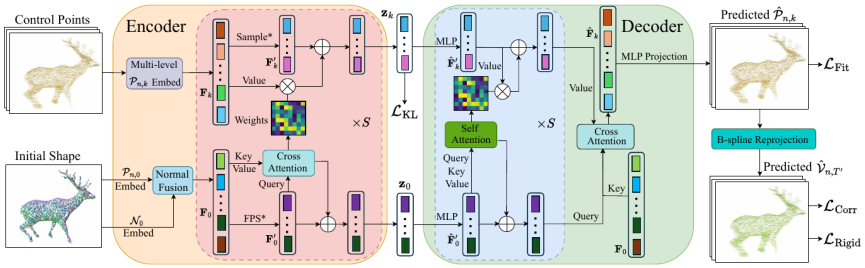

Figure 3. **B-spline VAE Pipeline.** Given the initial shape $(\mathcal{P}_{n,0}, \mathcal{N}_0)$ and control points $\mathcal{P}_{n,k}$, the *Encoder* compresses them into latent codes $\mathbf{z}_0$ and $\mathbf{z}_k$. The *Decoder* reconstructs the predicted control points $\hat{\mathcal{P}}_{n,k}$, which are then reprojected to point differences via the B-

Figure 3

Figure 4: 定性的比較

ベースラインに比べて、BiMotion のほうがテキストに沿った大きな動きと安定した形状を出せている例です。

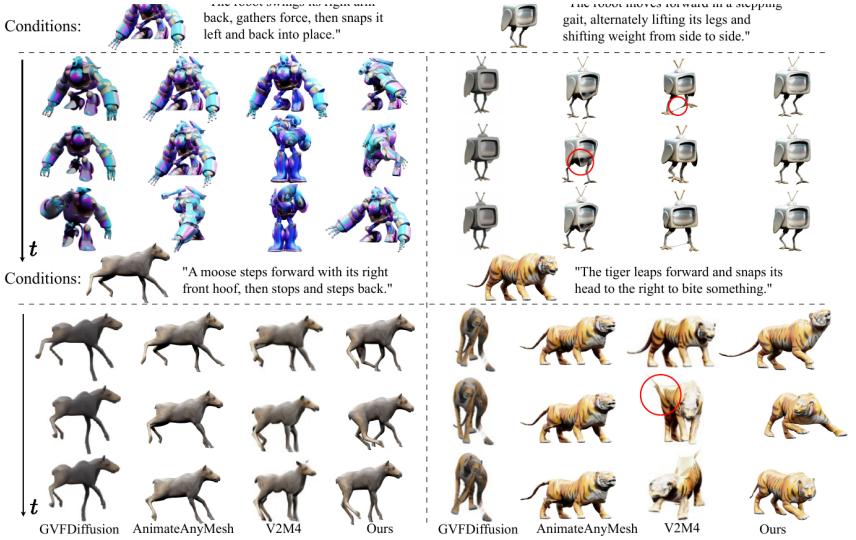

Figure 4. **Qualitative Comparisons.** Our method (BiMotion) results in superior motion quality and is more aligned with the user-provided text prompts. Artifacts for the baseline methods are highlighted in red. Please see the supplementary material for additional results.

Figure 4

Figures 5-10: アブレーションと頑健性

B-spline 表現、Laplacian 正則化、Normal Fusion、制御点埋め込み、局所剛性損失、メッシュ変更への頑健性をまとめたページです。

Figure 5. **B-spline Ablation.** B-spline interpolation from predicted control points achieves lower L1 error over the entire sequence than linear interpolation on sampled raw differences.

Figure 6. **Laplacian Regularizer L.** B-spline $\times 2$ interpolation comparison from a $T = 10$ mesh sequence comparing Ridge [36] and our Laplacian regularizer **L**. **L** produces more natural results.

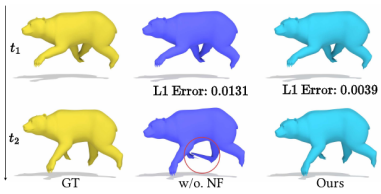

Figure 7. **Normal Fusion (NF) Ablation.** NF effectively separates nearby distinct parts. Without it, artifacts appear (see red).

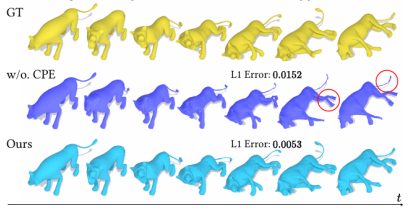

Figure 8. **Control-PE Ablation.** Our control-PE (Bottom) captures fine motion (*e.g.,* the lion's tail) and reduces artifacts (red circles) compared to conventional position encoding (Middle).

Figure 9. $\mathcal{L}_{\text{Rigid}}$ **Ablation.** Our local rigid loss reduces the red-circled artifacts during motion generation. Prompt: *"The pistol tilts up to an angled pose, then returns to forward-facing."*

(Eq. (11)) enforces piecewise consistency with the initial geometry across frames, helping retain shape identity during motion generation, as shown in Fig. 9.

Robustness to Meshing. Our dense-point training and normal fusion strategies are independent of fixed mesh topology, making our method robust to mesh changes (see Fig. 10) and capable of generating motion consistent with the user-provided input text, while AnimateAnyMesh fails.

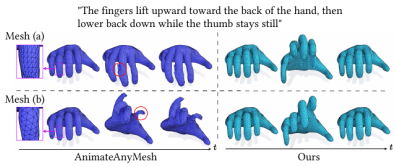

Figure 10. **Robustness to Meshing.** Ours produces consistent motion under mesh changes (Top to Bottom), whereas AnimateAnyMesh exhibits unstable motion and artifacts (red circles).

5. Discussion

Like all other generative tasks, improvements in motion generation depend on the availability of large and diverse dynamic sequences and sufficient compute. BiMotion nonetheless offers a complementary, staged contribution to character motion generation by demonstrating how to obtain continuous, compact, and efficient motion representations from variable-length sequences that can be used with constrained fixed-capacity models. This representation-centric view yields more expressive and plausible motions than SOTAs, and we expect these advantages to persist

Figures 5-10